

Отчет по результатам выполнения заданий практикума

Студент: Дзюба И.А. 316

8 декабря 2025 г.

Содержание

1	Описание Датасета	7
2	Теория ядерных оценок	8
3	Реализация и результаты	8
4	Выводы по данным распределения погодных параметров	9
4.1	Температура воздуха (Temp_C)	9
4.2	Атмосферное давление (Press_kPa)	10
4.3	Скорость ветра (Wind Speed_km/h)	11
4.4	Общие выводы	11
5	Анализ данных с использованием различных графиков	11
5.1	Распределение давления по типам погоды	11
5.2	Анализ среднего давления по типам погоды и времени суток	13
5.3	Boxplot и Stripchart анализа температуры и давления по типам погоды	15
5.4	Сравнение графиков, построенных на Python и R	17
6	Проверка выбросов с использованием тестов Граббса и Q- теста Диксона	17
6.1	Теоретические основы	17
6.1.1	Q-тест Диксона	17
6.1.2	Тест Граббса	18
7	Обоснование выбора параметра Press_kPa	18
8	Результаты проверки выбросов	18
8.1	Результаты теста Граббса	18
8.2	Результаты Q-теста Диксона	19
8.3	Применение критериев на сгенерированных данных	19
8.4	Заключение	19
8.5	Визуализация распределения давления	19
9	Методы восстановления пропусков в данных	20
9.1	Описание методов	21
9.2	Результаты тестирования	21

9.3	Визуализация восстановления пропусков	22
9.4	Сравнение результатов между Python и R	22
10	Анализ данных с помощью графиков эмпирических функций распределений	23
10.1	Графики эмпирических функций распределений (ECDF) .	23
10.1.1	Особенности ECDF	24
10.2	Данные для анализа	24
10.3	Визуализация ECDF	25
10.4	Графики квантиль-квантиль (Q-Q Plots)	26
10.4.1	Описание метода	26
10.4.2	Применение Q-Q Plots	29
10.5	Заключение	29
10.6	Метод огибающих	29
10.6.1	Теоретические основы	29
10.6.2	Анализ данных с помощью огибающих	29
10.6.3	Выводы и сравнение Python и R	31
10.6.4	Заключение	31
11	Критерии проверки нормальности данных	31
11.1	Тест Шапиро-Уилка (и Шапиро-Франсиса)	31
11.2	Тест Андерсона-Дарлинга	32
11.3	Критерий Крамера-фон Мизеса	32
11.4	Тест Колмогорова-Смирнова	32
11.5	Модификация Лиллиефорса теста Колмогорова-Смирнова	33
11.6	Заключение	33
12	Сравнение результатов проверки нормальности между Python и R	33
12.1	Сводные результаты тестов	34
12.2	Выводы по результатам сравнения Python и R	35
13	Анализ реальных данных на нормальность	36
13.1	Графики эмпирической функции распределения (ECDF) .	37
13.2	Графики квантиль-квантиль (Q-Q Plots)	38
13.3	Графики огибающих	39
13.4	Различия между Python и R	40
13.5	Анализ нормальности данных	40

13.6	Заключение	41
14	Проверка гипотез о средних значениях выборок с использованием критерия Стьюдента	41
14.1	Теоретические основы	41
14.1.1	Нулевая и альтернативная гипотезы	41
14.1.2	Условия применимости	42
14.1.3	Типы тестов	42
14.1.4	Результаты теста	42
14.2	Описание теста	43
14.3	Результаты тестов	43
14.4	Сравнение результатов Python и R	43
14.5	Выводы по сравнению Python и R	44
14.6	Общие выводы	44
15	Примечание о различиях в реализации	45
16	Корреляционные взаимосвязи в метеорологических данных	45
16.1	Выводы	45
16.2	Результаты корреляционного анализа	47
16.2.1	Результаты Python	47
16.2.2	Результаты R	48
16.3	Сравнение Python и R	48
16.4	Общие выводы	49
16.5	Практическое значение	50
17	Проверка зависимости между температурой и типом погоды с использованием различных тестов	50
17.1	Описание исследования	50
17.1.1	Категоризация данных	50
17.1.2	Подготовка данных	51
17.2	Результаты теста хи-квадрат	51
17.2.1	Вывод Python	51
17.2.2	Вывод R	51
17.3	Результаты точного теста Фишера	51
17.3.1	Вывод Python	51
17.3.2	Вывод R	52

17.4	Результаты теста МакНемара	52
17.4.1	Вывод Python	52
17.4.2	Вывод R	52
17.5	Выводы	53
17.6	Обсуждение различий между Python и R	53
18	Проверка наличия мультиколлинеарности в данных	53
19	Проверка мультиколлинеарности метеорологических переменных	53
19.1	Описание исследования	53
19.1.1	Категоризация данных	54
19.1.2	Подготовка данных	54
19.2	Корреляционная матрица	54
19.2.1	Вывод Python	54
19.2.2	Вывод R	54
19.3	Фактор инфляции дисперсии (VIF)	55
19.3.1	Вывод Python	55
19.3.2	Вывод R	55
19.4	Выводы	56
19.5	Обсуждение различий между Python и R	56
20	Анализ влияния погодных условий на температуру и давление с использованием ANOVA	57
20.1	Описание исследования	57
20.1.1	Параметры генерации данных для анализа	57
20.1.2	Исследуемые переменные	58
20.2	Результаты однофакторного ANOVA	58
20.2.1	Вывод Python	58
20.2.2	Вывод R	58
20.3	Результаты двухфакторного ANOVA (температура непрерывная)	58
20.3.1	Вывод Python	58
20.3.2	Вывод R	59
20.4	Результаты двухфакторного ANOVA (температура дискретная)	59
20.4.1	Вывод Python	59
20.4.2	Вывод R	59

20.5 Выводы	60
20.6 Обсуждение различий между Python и R	60
21 Аппроксимация данных с использованием регрессионных моделей	61
21.1 Описание исследования	61
21.2 Результаты анализа	61
21.2.1 LASSO регрессия (Python)	61
21.2.2 Полиномиальная регрессия с Ridge регуляризацией (Python)	62
21.2.3 Сравнение с R	62
21.3 Выводы	63
22 Общее сравнение Python и R	63
22.1 Общие наблюдения	63
22.2 Заключение	64
23 Выводы	64

1 Описание Датасета

Анализируемый датасет содержит информацию о 8784 почасовых измерениях погоды. Включенные столбцы предоставляют следующую информацию:

- **Date/Time:** Дата и время измерения (в формате ГГГГ-ММ-ДД ЧЧ:ММ:СС).
- **Temp_C:** Температура воздуха (в градусах Цельсия).
- **Dew Point Temp_C:** Температура точки росы (в градусах Цельсия).
- **Rel_Hum:** Относительная влажность воздуха (в процентах).
- **Wind Speed_km/h:** Скорость ветра (в километрах в час).
- **Visibility_km:** Видимость (в километрах).
- **Press_kPa:** Атмосферное давление (в килопаскалях).
- **Weather:** Погодные условия (например, "Туман" "Ясно" "Дождь" и т.д.).

На основе статистических характеристик можно выделить следующие ключевые моменты:

- Средняя температура воздуха составляет $8.80^{\circ}C$.
- Средняя температура точки росы равна $2.56^{\circ}C$.
- Средняя относительная влажность воздуха составляет 67.43%.
- Средняя скорость ветра равна 14.95 км/ч.
- Средняя видимость составляет 27.66 км.
- Среднее атмосферное давление равно 101.05 кПа.

Все данные представлены без пропусков, что значительно упрощает их анализ.

2 Теория ядерных оценок

Ядерные оценки плотности (Kernel Density Estimation, KDE) представляют собой метод, который используется для восстановления неизвестной функции плотности вероятности по данным выборки. Этот подход позволяет получить представление о распределении случайной величины без необходимости задавать его точную форму. В отличие от гистограмм, ядерная оценка обеспечивает более гладкую и точную аппроксимацию распределения.

Выражение для ядерной оценки плотности задается следующим образом:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

где:

- x_i — элементы выборки,
- h — ширина окна сглаживания (параметр сглаживания),
- K — функция ядра (чаще всего используется гауссово ядро).

Применение метода KDE позволяет глубже изучать распределение данных, особенно в случаях, когда данные имеют сложную структуру или не соответствуют стандартным теоретическим распределениям.

3 Реализация и результаты

Для аппроксимации распределений в Python и R были использованы библиотеки, поддерживающие метод KDE. Ниже представлены получившиеся графики KDE.

На рисунке ниже представлены два набора графиков: первый был создан с использованием Python, а второй — с использованием R.




Рис. 1: Графики, построенные на Python.

4 Выводы по данным распределения погодных параметров

4.1 Температура воздуха (Temp_C)

- **Гистограмма:** Распределение температуры воздуха имеет бимодальный характер с пиками при 0°C и 20°C, что соответствует сезонным изменениям температурного режима.
- **KDE:** Плавная кривая плотности подтверждает наличие двух выраженных максимумов. Распределение демонстрирует тяжелые как




Рис. 2: Графики, построенные на R.

левый, так и правый хвосты, что указывает на значительную вариативность температурных значений.

4.2 Атмосферное давление (Press_kPa)

- **Гистограмма:** Распределение атмосферного давления визуально наиболее близко к нормальному с основным пиком при 101 кПа, однако последующий анализ покажет отклонение от нормальности.
- **KDE:** Кривая плотности имеет выраженный пик в районе 101 кПа. Распределение характеризуется тяжелыми обоими хвостами, что свидетельствует о наличии экстремальных значений давления.

4.3 Скорость ветра (Wind Speed _km/h)

- **Гистограмма:** Распределение скорости ветра имеет асимметричный характер с основным пиком при 7 км/ч.
- **KDE:** Плавная кривая показывает выраженную асимметрию с легким левым хвостом и тяжелым правым хвостом, что типично для распределений скорости ветра - преобладание низких скоростей с редкими сильными порывами.

4.4 Общие выводы

- Распределение температуры демонстрирует четкую сезонную зависимость с двумя выраженными режимами - холодным и теплым.
- Атмосферное давление, несмотря на визуальную близость к нормальному распределению, имеет значительные отклонения в хвостах.
- Распределение скорости ветра соответствует типичным метеорологическим закономерностям с преобладанием слабых ветров и редкими сильными порывами.

5 Анализ данных с использованием различных графиков

Для анализа данных были использованы различные графические методы. Рассмотрим распределение атмосферного давления в зависимости от типа погодных условий.

5.1 Распределение давления по типам погоды

График conditional density plot демонстрирует распределение атмосферного давления для пяти наиболее распространенных типов погодных условий. Анализ позволяет выявить закономерности между атмосферным давлением и погодными явлениями.




Рис. 3: Conditional density plots распределения атмосферного давления по типам погоды, построенные с использованием Python и R.

Основные выводы:

- **Низкое давление при снегопаде:** Распределение давления для условий "Snow" смещено в область низких значений, что характерно для циклонной погоды с осадками.
- **Высокое давление при ясной погоде:** Типы "Mainly Clear" и "Clear" демонстрируют смещение распределения в область высоких значений давления, что соответствует антициклонным условиям.
- **Усредненное распределение для облачной погоды:** Категории "Mostly Cloudy" и "Cloudy" показывают среднее распределение давления. при давлении выше 99.

Заключение:

Анализ подтверждает метеорологическую закономерность: низкое давление ассоциируется с осадками (снег), в то время как высокое давление характерно для ясной погоды. Облачные условия занимают промежуточное положение в распределении атмосферного давления.

5.2 Анализ среднего давления по типам погоды и времени суток

Для анализа распределения атмосферного давления были использованы точечные диаграммы, построенные в Python и R, отображающие зависимость давления от различных факторов.




Рис. 4: Зависимость среднего давления от типа погоды, построенная с использованием Python.




Рис. 5: Зависимость среднего давления от часа суток, построенная с использованием R.

Вывод:

Анализ графиков показывает две различные закономерности:

- **По типам погоды (Python):** Среди примерно 20 типов погодных условий большинство демонстрируют незначительные различия в среднем давлении. Однако наблюдается выраженное снижение давления при снежной погоде и грозах, что соответствует метеорологической закономерности - низкое давление ассоциируется с интенсивными осадками.
- **По времени суток (R):** Распределение среднего давления в течение

ние суток похоже на синусоиду. Это отражает естественные суточные колебания атмосферного давления, связанные с термическими процессами в атмосфере.

5.3 Boxplot и Stripchart анализа температуры и давления по типам погоды

Для анализа зависимости метеорологических параметров от погодных условий были использованы два вида графиков: Boxplot (диаграмма размаха) и Stripchart (точечная диаграмма). Boxplot визуализирует распределение данных по квартилям, медиане и выбросам, а Stripchart показывает индивидуальные точки данных.

Boxplot анализа температуры (Python):

На графике Boxplot распределения температуры для пяти наиболее популярных типов погоды наблюдаются небольшие различия между большинством типов. Однако распределение температуры при снегопаде (Snow) существенно сдвинуто вниз относительно других категорий, что соответствует физической закономерности - снег обычно выпадает при низких температурах.




Рис. 6: Boxplot распределения температуры и давления по типам погоды.

Boxplot анализа давления (R):

Распределение давления для тех же пяти типов погоды демонстрирует небольшие различия между основными категориями. При этом, как и в анализе dotchart, средние значения давления примерно равны для большинства типов погоды.

Stripchart анализа давления (Python и R):

Точечные диаграммы давления подтверждают выводы boxplot анализа. Распределение давления при снегопаде характеризуется большей разреженностью и вытянутостью в область низких значений, в то время как для остальных типов погоды распределение более компактное.




Рис. 7: Stripchart распределения давления по типам погоды.

Выводы:

- Температура существенно ниже при снегопаде по сравнению с другими типами погоды.
- Распределение давления для большинства типов погоды имеет схожие характеристики со сходными средними значениями.
- При снегопаде наблюдается более широкий разброс значений давления с смещением в область низких значений.

- Полученные результаты соответствуют метеорологическим закономерностям: снегопады ассоциируются с низкими температурами и часто сопровождаются пониженным давлением.

5.4 Сравнение графиков, построенных на Python и R

Графики, построенные с использованием Python и R, демонстрируют практически идентичные результаты при анализе данных. Это объясняется использованием одинаковых алгоритмов обработки данных и расчета статистик, таких как медиана, квартильные значения и выбросы в Boxplot, а также точек данных в Stripchart.

Поскольку оба языка программирования используют одни и те же математические подходы, результаты анализа остаются идентичными. Незначительные отличия могут возникать только из-за особенностей внутренних реализаций библиотек, однако они не влияют на выводы. Таким образом, выбор между Python и R для данного анализа не влияет на интерпретацию данных, и оба инструмента предоставляют надежные и корректные результаты.

6 Проверка выбросов с использованием тестов Граббса и Q-теста Диксона

6.1 Теоретические основы

Для обнаружения выбросов в данных применяются различные статистические методы. В данном случае использованы два подхода: Q-тест Диксона и тест Граббса.

6.1.1 Q-тест Диксона

Q-тест предназначен для выявления выбросов в небольших выборках. Он основан на вычислении отношения между разницей минимального или максимального значения и общим диапазоном данных. Этот тест особенно эффективен для наборов данных, содержащих от 3 до 30 наблюдений, и требует, чтобы данные имели нормальное распределение, так как чувствителен к его отклонениям.

Статистика Q рассчитывается по формуле:

$$Q = \frac{|X_{\max} - X_{\min}|}{\text{range of the data}}$$

Если значение Q превышает критическое значение, соответствующее размеру выборки, то данное наблюдение считается выбросом.

6.1.2 Тест Граббса

Тест Граббса используется для идентификации одного выброса в данных с нормальным распределением. Он основывается на расчете статистики G , которая определяется как:

$$G = \frac{|X_{\text{outlier}} - \bar{X}|}{s}$$

где $\bar{X}$ — среднее арифметическое, а s — стандартное отклонение выборки.

Этот тест применяется только к данным, которые следуют нормальному распределению. Минимальное число наблюдений для корректного применения теста составляет 3.

Оба метода имеют свои ограничения, но в условиях корректного применения они позволяют эффективно определять выбросы в данных.

7 Обоснование выбора параметра Press_kPa

Для анализа выбрано атмосферное давление (Press_kPa), так как предварительный анализ показал, что его распределение наиболее близко к нормальному среди всех параметров в наборе данных. Это является важным условием для корректного применения тестов Граббса и Диксона, которые требуют, чтобы данные имели нормальное распределение.

8 Результаты проверки выбросов

8.1 Результаты теста Граббса

В результате применения теста Граббса к атмосферному давлению (Press_kPa) не было выявлено статистически значимых выбросов.

8.2 Результаты Q-теста Диксона

Применение Q-теста Диксона к 30 наибольшим значениям параметра Press_kPa также не выявило выбросов. Это говорит о том, что в указанных диапазонах экстремальные значения не выходят за пределы, установленные критерием теста.

8.3 Применение критериев на сгенерированных данных

Так как данные все же не являются нормальными, критерии не применимы, продемонстрируем применение критериев к сгенерированной выборке из нормального распределения:


Тест Граббса показал, что выбросов нет Q-тест Диксона был применен к подвыборке размера 30 элементов и показал, что выбросов так же нет, однако после добавления точки, -1000 к нормальным данным, оба критерия показывают, что выброс есть, следовательно критерии работают верно.

8.4 Заключение

Анализ показал, что ни тест Граббса, ни Q-тест Диксона не выявили статистически значимых выбросов в данных о атмосферном давлении. Это свидетельствует об отсутствии экстремальных значений, которые могли бы исказить результаты последующего анализа.


8.5 Визуализация распределения давления

Для наглядного представления распределения атмосферного давления были построены графики, отображающие распределение данных.



(a) График, построенный с использованием Python

Рис. 8: Box-plot распределения сгенерированных данных.



(a) График, построенный с использованием Python

(b) График, построенный с использованием R

Рис. 9: Box-plot распределения атмосферного давления.

На графиках представлено распределение давления, подтверждающее отсутствие выраженных выбросов. Как и ранее, использование разных языков не повлияло на результат визуализации.

9 Методы восстановления пропусков в данных

Восстановление пропущенных данных — ключевая задача при подготовке данных для анализа. В этом разделе рассмотрены пять подходов: заполнение среднего значения, медианой, модой, интерполяция соседними значениями и метод k -ближайших соседей (KNN). Каждый из методов

протестирован на данных о давлении (Press_kPa) с искусственно созданными пропусками.

9.1 Описание методов

1. **Заполнение среднего значения:** Пропущенные значения заменяются средним значением всех доступных данных в столбце. Этот метод прост в реализации, но может быть неэффективен при наличии выбросов.
2. **Заполнение медианным значением:** Пропуски заполняются медианным значением всех имеющихся данных. Метод устойчив к выбросам и подходит для данных с асимметрией.
3. **Заполнение модой:** Пропущенные значения заменяются наиболее часто встречающимся значением в столбце. Подходит для категориальных данных или данных с выраженной модой.
4. **Интерполяция соседними значениями:** Для каждого пропуска вычисляется среднее значение между предыдущим и последующим наблюдениями. Эффективен для временных рядов и плавно изменяющихся данных.
5. **Метод k-ближайших соседей (KNN):** Пропуски заполняются на основе значений ближайших объектов в многомерном пространстве признаков. Учитывает взаимосвязи между переменными.

9.2 Результаты тестирования


Для оценки точности методов была рассчитана среднеквадратическая ошибка (MSE) восстановления пропусков. Результаты следующие:

- Среднее значение: 0.834
- Медиана: 0.834
- Мода: 0.839
- Интерполяция соседями: 0.034
- KNN (k=2): 0.684


На основе полученных результатов интерполяция соседними значениями продемонстрировала наименьшую ошибку, что делает её предпочтительным методом для данного набора данных. Высокая эффективность этого метода объясняется непрерывной зависимостью атмосферного давления от времени - давление изменяется плавно, и значения в соседние моменты времени сильно коррелированы. KNN метод показал среднюю эффективность, в то время как методы на основе статистик (среднее, медиана, мода) оказались наименее точными.

9.3 Визуализация восстановления пропусков

Для наглядности результаты восстановления пропусков были визуализированы на гистограммах, построенных с использованием Python. Все гистограммы построены в одинаковом диапазоне (5%–95% квантили) для обеспечения сопоставимости.



(a) На Python



(b) на R

Рис. 10: Распределения до/после заполнения пропусков.

9.4 Сравнение результатов между Python и R

В рамках данного исследования в Python были протестированы пять методов восстановления пропусков, тогда как в R использовались только два метода: заполнение медианой и KNN. Результаты показывают, что:

- Метод интерполяции соседними значениями в Python показал наилучший результат ($MSE = 0.034$)

- KNN метод в Python показал $MSE = 0.684$, что значительно хуже интерполяции соседями
- Статистические методы (среднее, медиана, мода) показали схожую низкую эффективность

Различия в подходах между Python и R обусловлены фокусом исследования: в Python проводилось комплексное сравнение multiple методов, в то время как в R исследование было сконцентрировано на наиболее распространенных подходах.

Таким образом, для данных с плавными изменениями и временной структурой (таких как атмосферное давление) рекомендуется использование интерполяции соседними значениями, тогда как KNN может быть полезен при наличии взаимосвязанных признаков в данных.

10 Анализ данных с помощью графиков эмпирических функций распределений

10.1 Графики эмпирических функций распределений (ECDF)

Графики эмпирической функции распределения (Empirical Cumulative Distribution Function, ECDF) являются удобным инструментом для визуализации распределения данных. Они показывают накопленную вероятность того, что случайная величина примет значение меньше или равно заданному. Построение ECDF осуществляется следующим образом:

- Все значения выборки сортируются по возрастанию.
- Для каждого значения вычисляется доля элементов, которые меньше или равны этому значению.
- Результат отображается в виде ступенчатой линии, где каждая ступенька соответствует одному наблюдению.

ECDF предоставляет детальную информацию о распределении данных, позволяя выявить их центральные тенденции, отклонения и асимметрии. Этот график полезен для анализа данных независимо от их предполагаемого распределения.

10.1.1 Особенности ECDF

- **Гладкость:** Для больших выборок график становится более плавным за счёт увеличения числа наблюдений. Для малых выборок график будет ступенчатым.
- **Центр распределения:** Медиана выборки отображается в центре графика. Если данные симметричны, график будет относительно сбалансированным.
- **Поведение концов графика:** Низкие и высокие значения данных отображаются на концах графика. Для нормального распределения график плавно приближается к 1.
- **Влияние стандартного отклонения:** Чем больше стандартное отклонение, тем более растянутым становится график, так как данные распределяются на большем интервале.

10.2 Данные для анализа

Для анализа были сгенерированы выборки с использованием нормального распределения с различными параметрами в Python и R:

В Python использовались следующие выборки:

- **data1:** 100 элементов, нормальное распределение, среднее $\mu = 0.00$, стандартное отклонение $\sigma = 1.00$
- **data2:** 100 элементов, нормальное распределение, среднее $\mu = 4.33$, стандартное отклонение $\sigma = 2.72$
- **data3:** 100 элементов, нормальное распределение, среднее $\mu = 4.33$, стандартное отклонение $\sigma = 7.39$
- **data4:** 5000 элементов, нормальное распределение, среднее $\mu = 0.00$, стандартное отклонение $\sigma = 1.00$
- **data5:** 5000 элементов, нормальное распределение, среднее $\mu = 4.33$, стандартное отклонение $\sigma = 2.72$
- **data6:** 5000 элементов, нормальное распределение, среднее $\mu = 4.33$, стандартное отклонение $\sigma = 7.39$

В R использовались следующие выборки:

- **data1:** 50 элементов, нормальное распределение, среднее $\mu = 0$, стандартное отклонение $\sigma = 1$
- **data2:** 50 элементов, нормальное распределение, среднее $\mu = 5$, стандартное отклонение $\sigma = 10$
- **data3:** 5000 элементов, нормальное распределение, среднее $\mu = 0$, стандартное отклонение $\sigma = 1$
- **data4:** 5000 элементов, нормальное распределение, среднее $\mu = 5$, стандартное отклонение $\sigma = 10$

10.3 Визуализация ECDF

На следующих графиках представлены эмпирические функции распределений для каждой из указанных выборок.




Рис. 11: График эмпирической функции распределения (ECDF), построенный с использованием Python




Рис. 12: График эмпирической функции распределения (ECDF), построенный с использованием R

10.4 Графики квантиль-квантиль (Q-Q Plots)

Графики квантиль-квантиль (Quantile-Quantile Plots, Q-Q Plots) являются мощным инструментом для анализа соответствия распределения данных теоретическому распределению. Они помогают визуально оценить, насколько данные соответствуют, например, нормальному, экспоненциальному или любому другому распределению.


10.4.1 Описание метода

Метод Q-Q Plot основывается на сравнении квантилей эмпирического распределения данных с квантилями заданного теоретического распределения:


- Квантили данных рассчитываются на основе их рангового распределения.

- Квантили теоретического распределения вычисляются для тех же процентилей, что и квантили данных.
- Наблюдаемые и теоретические квантили отображаются в виде точек на графике.

Если распределение данных совпадает с теоретическим, точки на графике будут лежать вдоль прямой линии, указывающей на соответствие. Отклонения от прямой линии свидетельствуют о нарушении предположений о распределении.



(a) Q-Q Plot, построенный с использованием Python



(b) Q-Q Plot, построенный с использованием R

Рис. 13: Сравнение Q-Q Plots, построенных с использованием Python и R, для проверки соответствия данных нормальному распределению.

10.4.2 Применение Q-Q Plots

Графики квантиль-квантиль широко применяются для:

- Проверки нормальности распределения данных перед статистическим анализом.
- Обнаружения выбросов или асимметрии в данных.
- Сравнения различных наборов данных или моделей распределения.

10.5 Заключение

На представленных Q-Q Plots (Python и R) точки графиков в основном располагаются вдоль прямой линии, что подтверждает соответствие данных нормальному распределению.

10.6 Метод огибающих

10.6.1 Теоретические основы


Метод огибающих применяется для анализа экстремальных значений в распределении данных. Он включает построение:

- **Верхней огибающей:** Кривая, соединяющая максимальные значения в данных.
- **Нижней огибающей:** Кривая, соединяющая минимальные значения в данных.


Этот метод позволяет изучать отклонения распределения данных от теоретической модели, выявлять тренды, выбросы и асимметрии.

10.6.2 Анализ данных с помощью огибающих

Для анализа с использованием метода огибающих были построены графики на основе данных, сгенерированных из нормальных распределений с различными параметрами. Графики были созданы с использованием Python и R.



(а) Огибающие, построенные с использованием Python



(б) Огибающие, построенные с использованием R

Рис. 14: Графики метода огибающих для анализа распределения данных.

10.6.3 Выводы и сравнение Python и R

Результаты, полученные с использованием Python и R, практически идентичны. Это объясняется использованием схожих алгоритмов для вычисления экстремальных значений и построения кривых.

10.6.4 Заключение

Метод огибающих является полезным инструментом для анализа распределения данных. Он наглядно демонстрирует влияние параметров распределения, таких как стандартное отклонение, на поведение данных. Сравнение Python и R показало, что оба инструмента предоставляют точные результаты, и выбор языка зависит от предпочтений пользователя и особенностей задачи.

11 Критерии проверки нормальности данных

В данном разделе представлены основные статистические тесты для проверки нормальности распределения данных, включая краткое теоретическое описание каждого метода.

11.1 Тест Шапиро-Уилка (и Шапиро-Франсиа)

Теория: Тест Шапиро-Уилка проверяет нормальность данных, основываясь на линейности точек на Q-Q графике. Он оценивает, насколько сильно данные отклоняются от прямой линии, которая соответствует нормальному распределению. Значения статистики теста близкие к 1 свидетельствуют о нормальности. Тест наиболее эффективен для выборок размером до 5000 наблюдений.

Особенности:

- Используется для малых и средних выборок.
- Подходит для симметричных распределений.
- Модификация Шапиро-Франсиа применяется для больших выборок и данных с высокими значениями.

11.2 Тест Андерсона-Дарлинга

Теория: Этот тест оценивает нормальность данных, учитывая взвешенные отклонения эмпирической функции распределения (ECDF) от теоретической. Он придаёт больший вес отклонениям в хвостах распределения, что делает его более чувствительным к отклонениям от нормальности.

Особенности:

- Подходит для малых и средних выборок.
- Особо эффективен для данных с важными отклонениями в хвостах распределения.

11.3 Критерий Крамера-фон Мизеса

Теория: Этот тест оценивает согласованность эмпирической функции распределения (ECDF) с теоретической, суммируя квадрат отклонений между ними. Он особенно чувствителен к отклонениям в центральной части распределения.

Особенности:

- Более универсален по сравнению с другими тестами для данных со сложными распределениями.
- Используется для малых и средних выборок.

11.4 Тест Колмогорова-Смирнова

Теория: Этот тест проверяет нормальность, оценивая максимальное отклонение эмпирической функции распределения (ECDF) от теоретической функции. Он подходит для любых объёмов выборки и не предполагает каких-либо специфических параметров.

Особенности:

- Прост в интерпретации.
- Универсален и применяется для различных типов распределений.
- Чувствителен к отклонениям в хвостах распределения.

11.5 Модификация Лиллиефорса теста Колмогорова-Смирнова

Теория: Это модификация теста Колмогорова-Смирнова, предназначенная для проверки нормальности данных. В отличие от оригинального теста, здесь параметры распределения (среднее и дисперсия) оцениваются непосредственно из выборки, что делает тест более адаптированным.

Особенности:

- Учитывает реальные параметры распределения, что делает его подходящим для практических задач.
- Эффективен для малых и средних выборок.

11.6 Заключение

Каждый из перечисленных тестов имеет свои особенности и область применения. Выбор метода зависит от объёма выборки, свойств данных (например, симметрия или наличие выбросов) и цели анализа.

12 Сравнение результатов проверки нормальности между Python и R

Для проверки нормальности распределения данных были проведены тесты на Python и R с использованием различных статистических критериев. Тесты проводились на данных, сгенерированных из нормальных распределений с различными параметрами: $N(0, 1)$, $N(0, 2)$, $N(2, 1)$, с объёмом выборки 100 и 1000 наблюдений.

12.1 Сводные результаты тестов

Тест	Распределение	p-value	Результат (=0.1)
Колмогоров-Смирнов	$N(0, 1), n = 100$	0.970967	не отвергнута
Колмогоров-Смирнов	$N(4.33, 2.72), n = 100$	0.789830	не отвергнута
Колмогоров-Смирнов	$N(4.33, 7.39), n = 100$	0.964616	не отвергнута
Колмогоров-Смирнов	$N(0, 1), n = 5000$	0.698898	не отвергнута
Колмогоров-Смирнов	$N(4.33, 2.72), n = 5000$	0.975453	не отвергнута
Колмогоров-Смирнов	$N(4.33, 7.39), n = 5000$	0.859331	не отвергнута
Шапиро-Уилк	$N(0, 1), n = 100$	0.151967	не отвергнута
Шапиро-Уилк	$N(4.33, 2.72), n = 100$	0.864656	не отвергнута
Шапиро-Уилк	$N(4.33, 7.39), n = 100$	0.895335	не отвергнута
Шапиро-Уилк	$N(0, 1), n = 5000$	0.160072	не отвергнута
Шапиро-Уилк	$N(4.33, 2.72), n = 5000$	0.716258	не отвергнута
Шапиро-Уилк	$N(4.33, 7.39), n = 5000$	0.368818	не отвергнута
Андерсон-Дарлинг	$N(0, 1), n = 100$	0.274052	не отвергнута
Андерсон-Дарлинг	$N(4.33, 2.72), n = 100$	0.226545	не отвергнута
Андерсон-Дарлинг	$N(4.33, 7.39), n = 100$	0.276349	не отвергнута
Андерсон-Дарлинг	$N(0, 1), n = 5000$	0.371956	не отвергнута
Андерсон-Дарлинг	$N(4.33, 2.72), n = 5000$	0.246080	не отвергнута
Андерсон-Дарлинг	$N(4.33, 7.39), n = 5000$	0.311884	не отвергнута
Крамер-фон Мизес	$N(0, 1), n = 100$	0.951009	не отвергнута
Крамер-фон Мизес	$N(4.33, 2.72), n = 100$	0.974366	не отвергнута
Крамер-фон Мизес	$N(4.33, 7.39), n = 100$	0.926265	не отвергнута
Крамер-фон Мизес	$N(0, 1), n = 5000$	0.842748	не отвергнута
Крамер-фон Мизес	$N(4.33, 2.72), n = 5000$	0.962366	не отвергнута
Крамер-фон Мизес	$N(4.33, 7.39), n = 5000$	0.905519	не отвергнута
Лиллиефорс	$N(0, 1), n = 100$	0.822904	не отвергнута
Лиллиефорс	$N(4.33, 2.72), n = 100$	0.401133	не отвергнута
Лиллиефорс	$N(4.33, 7.39), n = 100$	0.798554	не отвергнута
Лиллиефорс	$N(0, 1), n = 5000$	0.286205	не отвергнута
Лиллиефорс	$N(4.33, 2.72), n = 5000$	0.862314	не отвергнута
Лиллиефорс	$N(4.33, 7.39), n = 5000$	0.537163	не отвергнута
Шапиро-Франсиа	$N(0, 1), n = 100$	0.151967	не отвергнута
Шапиро-Франсиа	$N(4.33, 2.72), n = 100$	0.864656	не отвергнута
Шапиро-Франсиа	$N(4.33, 7.39), n = 100$	0.895335	не отвергнута
Шапиро-Франсиа	$N(0, 1), n = 5000$	0.160072	не отвергнута
Шапиро-Франсиа	$N(4.33, 2.72), n = 5000$	0.716258	не отвергнута
Шапиро-Франсиа	$N(4.33, 7.39), n = 5000$	0.368818	не отвергнута

Таблица 1: Результаты тестов проверки нормальности для данных, сгенерированных в Python. Все p-value > 0.1, поэтому при уровне значимости =0.1 все тесты не отвергают нулевую гипотезу о нормальности. Наибольшее p-value = 0.975453, наименьшее = 0.151967.

Тест	Распределение	p-value	Результат (=0.05)
Колмогоров-Смирнов	$N(0, 1), n = 50$	0.7729	не отвергнута
Колмогоров-Смирнов	$N(5, 10), n = 50$	0.8835	не отвергнута
Колмогоров-Смирнов	$N(0, 1), n = 5000$	0.9870	не отвергнута
Колмогоров-Смирнов	$N(5, 10), n = 5000$	0.9725	не отвергнута
Шапиро-Уилк	$N(0, 1), n = 50$	0.9656	не отвергнута
Шапиро-Уилк	$N(5, 10), n = 50$	0.5944	не отвергнута
Шапиро-Уилк	$N(0, 1), n = 5000$	0.3661	не отвергнута
Шапиро-Уилк	$N(5, 10), n = 5000$	0.8735	не отвергнута
Андерсон-Дарлинг	$N(0, 1), n = 50$	$< 2.2 \times 10^{-16}$	отвергнута
Андерсон-Дарлинг	$N(5, 10), n = 50$	0.5589	не отвергнута
Андерсон-Дарлинг	$N(0, 1), n = 5000$	0.5421	не отвергнута
Андерсон-Дарлинг	$N(5, 10), n = 5000$	0.8971	не отвергнута
Крамер-фон Мизес	$N(0, 1), n = 50$	7.37×10^{-10}	отвергнута
Крамер-фон Мизес	$N(5, 10), n = 50$	0.5670	не отвергнута
Крамер-фон Мизес	$N(0, 1), n = 5000$	0.7374	не отвергнута
Крамер-фон Мизес	$N(5, 10), n = 5000$	0.7945	не отвергнута
Лиллиефорс	$N(0, 1), n = 50$	3.56×10^{-11}	отвергнута
Лиллиефорс	$N(5, 10), n = 50$	0.5937	не отвергнута
Лиллиефорс	$N(0, 1), n = 5000$	0.8912	не отвергнута
Лиллиефорс	$N(5, 10), n = 5000$	0.8221	не отвергнута
Шапиро-Франсиа	$N(0, 1), n = 50$	0.8867	не отвергнута
Шапиро-Франсиа	$N(5, 10), n = 50$	0.6330	не отвергнута
Шапиро-Франсиа	$N(0, 1), n = 5000$	0.3637	не отвергнута
Шапиро-Франсиа	$N(5, 10), n = 5000$	0.9548	не отвергнута

Таблица 2: Результаты тестов проверки нормальности для данных, сгенерированных в R. Большинство тестов не отвергает гипотезу о нормальности. Исключения: тесты Андерсона-Дарлинга и Крамера-фон Мизеса для data1 ($N(0, 1), n = 50$) показывают p-value < 0.05 , что может быть связано с малым размером выборки или особенностями реализации тестов.

12.2 Выводы по результатам сравнения Python и R

- Во всех тестах результаты p-value как на Python, так и на R свидетельствуют об отсутствии оснований для отклонения гипотезы о

нормальности данных.


- Python предоставляет удобные инструменты для быстрого выполнения тестов и анализа, в то время как R предлагает более широкий набор специализированных функций и параметров для работы с тестами.

Таким образом, оба языка успешно решают задачу проверки нормальности распределения, и выбор инструмента зависит от предпочтений пользователя и целей анализа.

13 Анализ реальных данных на нормальность


Для анализа реальных данных использовались графики эмпирической функции распределения (ECDF), квантиль-квантиль (Q-Q) графики и графики огибающих. Анализ проводился для параметра давление (Press kPa)

13.1 Графики эмпирической функции распределения (ECDF)



(a) ECDF для давления, построенные на Python


Эмпирическая функция распределения




(b) ECDF для давления, построенные на R

Рис. 15: Графики ECDF для давления.

13.2 Графики квантиль-квантиль (Q-Q Plots)




(a) Q-Q Plots для давления, построенные на Python




(b) Q-Q Plots для давления, построенные на R

Рис. 16: Графики квантиль-квантиль для давления.

13.3 Графики огибающих



(а) Огибающие для давления, построенные на Python



(б) Огибающие для давления, построенные на R

Рис. 17: Графики огибающих для давления.

Тест	Параметр	Python, p-value	R, p-value	Результат
Колмогоров-Смирнов	Давление (Press_kPa)	7.25×10^{-10}	$< 2.2 \times 10^{-16}$	отвергнуто
Шапиро-Уилк	Давление (Press_kPa)	1.28×10^{-20}	$< 2.2 \times 10^{-16}$	отвергнуто
Андерсон-Дарлинг	Давление (Press_kPa)	13.468486*	$< 2.2 \times 10^{-16}$	отвергнуто
Крамер-фон Мизес	Давление (Press_kPa)	1.40×10^{-5}	7.37×10^{-10}	отвергнуто
Лиллиефорс	Давление (Press_kPa)	0.001	3.56×10^{-11}	отвергнуто
Шапиро-Франсиа	Давление (Press_kPa)	1.28×10^{-20}	$< 2.2 \times 10^{-16}$	отвергнуто

Таблица 3: Результаты тестов проверки нормальности для данных давления (Press_kPa) в Python и R. Все тесты в обоих языках показывают $p\text{-value} < 0.05$, поэтому нулевая гипотеза о нормальности отвергается на уровне значимости 5%. *Для теста Андерсона-Дарлинга в Python указана статистика теста.

13.4 Различия между Python и R

Анализ нормальности данных был выполнен на Python и R с использованием различных статистических тестов. Основные наблюдения:

- В обоих языках тесты показывают идентичные результаты относительно принятия или отклонения гипотезы о нормальности данных.
- Незначительные различия наблюдаются в значениях $p\text{-value}$, что связано с различиями в численной реализации методов в Python и R. Например, тест Колмогорова-Смирнова в R выдавал предупреждения из-за наличия одинаковых значений в данных, что не учитывается в реализации Python.
- R демонстрирует более точную обработку специфичных условий данных (например, предупреждения о наличии одинаковых значений), что может быть полезно для более детального анализа.

13.5 Анализ нормальности данных

На основе результатов всех тестов можно сделать следующие выводы:

- Данные давления (Press_kPa) не соответствуют нормальному распределению, так как $p\text{-value}$ во всех тестах оказался значительно меньше порогового уровня значимости ($\alpha = 0.05$).

- Все шесть тестов нормальности (Колмогорова-Смирнова, Шапиро-Уилка, Андерсона-Дарлинга, Крамера-фон Мизеса, Лиллиефорса и Шапиро-Франсия) единогласно отвергают нулевую гипотезу о нормальности распределения давления.
- Результаты согласованы между Python и R: в обоих языках программирования получены экстремально малые p-value ($< 10^{-5}$), что свидетельствует о сильных статистических доказательствах против нормальности распределения.

13.6 Заключение

Результаты анализа показывают, что данные давления (Press_kPa) не подчиняются нормальному распределению. Все шесть применённых тестов нормальности (Колмогорова-Смирнова, Шапиро-Уилка, Андерсона-Дарлинга, Крамера-фон Мизеса, Лиллиефорса и Шапиро-Франсия) демонстрируют статистически значимые отклонения от нормальности с p-value < 0.05 . Это указывает на необходимость использования непараметрических методов или методов, устойчивых к отклонениям от нормальности, при дальнейшем статистическом анализе данных давления.

14 Проверка гипотез о средних значениях выборок с использованием критерия Стьюдента

14.1 Теоретические основы

Критерий Стьюдента предназначен для проверки гипотез о средних значениях двух выборок. Его основная цель — определить, является ли разница между средними значениями статистически значимой или случайной.

14.1.1 Нулевая и альтернативная гипотезы

- **Нулевая гипотеза (H_0):** Средние значения двух выборок равны ($\mu_1 = \mu_2$).

- **Альтернативная гипотеза (H_1):** Средние значения двух выборок различаются ($\mu_1 \neq \mu_2$ для двустороннего теста) или одно среднее больше/меньше другого ($\mu_1 < \mu_2$ или $\mu_1 > \mu_2$ для одностороннего теста).

14.1.2 Условия применимости

Для корректного применения критерия Стьюдента должны выполняться следующие условия:

- Данные в выборках должны быть нормально распределены.
- Выборки должны быть независимыми.
- Дисперсии двух выборок могут быть равными или различными (в зависимости от используемой версии теста).
- Размер выборки должен быть достаточным для обеспечения статистической мощности.

14.1.3 Типы тестов

- **Двусторонний тест:** Проверяет, отличаются ли средние значения выборок в любом направлении.
- **Односторонний тест:** Проверяет, является ли одно среднее значение больше или меньше другого.

14.1.4 Результаты теста

Результаты теста интерпретируются на основе значения p -value:

- Если p -value меньше уровня значимости (α), то нулевая гипотеза (H_0) отвергается, что свидетельствует о значимом различии между средними значениями.
- Если p -value больше α , то оснований для отклонения H_0 нет.

14.2 Описание теста

Был проведён тест Стьюдента для проверки равенства средних значений двух выборок: **Sample 1** и **Sample 2**. Средние значения выборок составляют 1 и 3 соответственно, при равных дисперсиях ($\sigma^2 = 10$). Выборки нормальны и имеют одинаковую дисперсию, что делает применение теста обоснованным. Рассмотрены как двусторонний, так и односторонний тесты.

14.3 Результаты тестов

- **Двусторонний тест:** При доверительном уровне 0.95 нулевая гипотеза (H_0) была отвергнута. Это указывает на наличие статистически значимого различия между средними значениями выборок.
- **Односторонние тесты:** Результаты подтверждают, что среднее значение выборки **SData1** меньше среднего значения выборки **SData2**.

14.4 Сравнение результатов Python и R

- **Т-тест Стьюдента:** Оба языка показывают одинаковые выводы о значимых различиях между выборками, однако наблюдаются расхождения в величине р-значений:
 - Python: двустороннее $p = 0.000978$, левостороннее $p = 0.000489$
 - R: двустороннее $p = 5.22 \times 10^{-38}$, левостороннее $p = 2.61 \times 10^{-38}$
- **Мощность критерия:** Наблюдаются существенные различия в оценке мощности:
 - Python: мощность левостороннего критерия при $\alpha = 0.05$ составляет 0.951
 - R: мощность левостороннего критерия при $\alpha = 0.05$ составляет 0
- **Тесты на однородность дисперсий:** Результаты более согласованы:
 - Все тесты (Фишера, Левене, Бартлетта, Флингера) показывают одинаковые выводы о равенстве дисперсий

- Р-значения сопоставимы (Python: 0.220-0.382, R: 0.331-0.443)
- **U-тест Манна-Уитни:** Результаты качественно совпадают, но с различиями в численных значениях:
 - Python: двустороннее $p = 0.00370$
 - R: двустороннее $p = 2.08 \times 10^{-35}$

14.5 Выводы по сравнению Python и R

- **Качественные выводы:** Оба языка дают одинаковые качественные выводы о наличии статистически значимых различий между выборками `SData1` и `SData2`.
- **Количественные различия:** Наблюдаются значительные расхождения в величинах р-значений, особенно для параметрических тестов. Это может быть связано с:
 - Различиями в алгоритмах реализации статистических тестов
 - Особенности генерации случайных чисел
 - Методами расчёта р-значений (точные vs аппроксимированные)
- **Мощность критерия:** Существенное расхождение в оценке мощности критерия требует дополнительного исследования и может указывать на разные методы расчёта этого параметра.
- **Непараметрические тесты:** Дают более согласованные результаты, что подтверждает их устойчивость к различиям в реализации.
- **Тесты на однородность дисперсий:** Показывают высокую степень согласованности между Python и R.

14.6 Общие выводы

- Средние значения выборок `SData1` и `SData2` существенно различаются
- Среднее значение `SData1` статистически значимо меньше, чем среднее значение `SData2`

- Дисперсии выборок не различаются статистически значимо
- Непараметрические тесты подтверждают различия в распределениях выборок
- Несмотря на количественные различия в р-значениях, качественные выводы одинаковы для Python и R
- Для критических исследований рекомендуется проверять результаты с использованием нескольких статистических пакетов и учитывать возможные различия в алгоритмах

15 Примечание о различиях в реализации

- Различия в р-значениях между Python и R могут быть связаны с:
 - Разными методами расчёта статистики (точные формулы vs аппроксимации)
 - Особенности генерации нормальных распределений
 - Точностью численных вычислений
 - Коррекцией на непрерывность
- Для обеспечения воспроизводимости рекомендуется:
 - Использовать одинаковые seed для генераторов случайных чисел
 - Проверять эквивалентность методов статистического анализа
 - Документировать версии используемых пакетов и их настройки

16 Корреляционные взаимосвязи в метеорологических данных

16.1 Выводы

На основании проведённого корреляционного анализа метеорологических параметров были сделаны следующие наблюдения:

- Наблюдается сильная положительная корреляция между температурой и точкой росы (0.93 по Пирсону), что соответствует физической закономерности — более высокая температура воздуха способна удерживать больше влаги.
- Влажность имеет умеренную отрицательную корреляцию с видимостью (-0.63 по Пирсону), что объясняется образованием тумана и дымки при высокой влажности.
- Скорость ветра показывает слабую отрицательную корреляцию с давлением (-0.36 по Пирсону), что может быть связано с атмосферными фронтами.
- Ранговые коэффициенты корреляции (Спирмена и Кендалла) показывают сходные, но несколько отличные от линейных (Пирсона) значения, что может свидетельствовать о нелинейных компонентах в зависимостях.

16.2 Результаты корреляционного анализа

16.2.1 Результаты Python

Метод	Temp_C	Dew Point	Rel_Hum	Wind Speed	Visibility	Press
Пирсон						
Temp_C	1.000	0.933	-0.220	-0.062	0.273	-0.236
Dew Point	0.933	1.000	0.139	-0.096	0.051	-0.321
Rel_Hum	-0.220	0.139	1.000	-0.093	-0.634	-0.231
Wind Speed	-0.062	-0.096	-0.093	1.000	0.005	-0.357
Visibility	0.273	0.051	-0.634	0.005	1.000	0.232
Press	-0.236	-0.321	-0.231	-0.357	0.232	1.000
Спирмен						
Temp_C	1.000	0.925	-0.228	-0.048	0.201	-0.245
Dew Point	0.925	1.000	0.126	-0.090	-0.012	-0.336
Rel_Hum	-0.228	0.126	1.000	-0.121	-0.576	-0.241
Wind Speed	-0.048	-0.090	-0.121	1.000	-0.042	-0.319
Visibility	0.201	-0.012	-0.576	-0.042	1.000	0.263
Press	-0.245	-0.336	-0.241	-0.319	0.263	1.000
Кендалл						
Temp_C	1.000	0.768	-0.150	-0.031	0.150	-0.164
Dew Point	0.768	1.000	0.087	-0.061	-0.009	-0.229
Rel_Hum	-0.150	0.087	1.000	-0.085	-0.451	-0.163
Wind Speed	-0.031	-0.061	-0.085	1.000	-0.032	-0.224
Visibility	0.150	-0.009	-0.451	-0.032	1.000	0.195
Press	-0.164	-0.229	-0.163	-0.224	0.195	1.000

Таблица 4: Коэффициенты корреляции метеорологических параметров, рассчитанные на Python.

16.2.2 Результаты R

Метод	Temp_C	Dew Point	Rel_Hum	Wind Speed	Visibility	Press
Пирсон						
Temp_C	1.000	0.933	-0.220	-0.062	0.273	-0.236
Dew Point	0.933	1.000	0.139	-0.096	0.051	-0.321
Rel_Hum	-0.220	0.139	1.000	-0.093	-0.634	-0.231
Wind Speed	-0.062	-0.096	-0.093	1.000	0.005	-0.357
Visibility	0.273	0.051	-0.634	0.005	1.000	0.232
Press	-0.236	-0.321	-0.231	-0.357	0.232	1.000
Спирмен						
Temp_C	1.000	0.925	-0.228	-0.048	0.201	-0.245
Dew Point	0.925	1.000	0.126	-0.090	-0.012	-0.336
Rel_Hum	-0.228	0.126	1.000	-0.121	-0.576	-0.241
Wind Speed	-0.048	-0.090	-0.121	1.000	-0.042	-0.319
Visibility	0.201	-0.012	-0.576	-0.042	1.000	0.263
Press	-0.245	-0.336	-0.241	-0.319	0.263	1.000
Кендалл						
Temp_C	1.000	0.768	-0.150	-0.031	0.150	-0.164
Dew Point	0.768	1.000	0.087	-0.061	-0.009	-0.229
Rel_Hum	-0.150	0.087	1.000	-0.085	-0.451	-0.163
Wind Speed	-0.031	-0.061	-0.085	1.000	-0.032	-0.224
Visibility	0.150	-0.009	-0.451	-0.032	1.000	0.195
Press	-0.164	-0.229	-0.163	-0.224	0.195	1.000

Таблица 5: Коэффициенты корреляции метеорологических параметров, рассчитанные на R.

16.3 Сравнение Python и R

- **Полное совпадение:** Результаты корреляционного анализа, выполненного на Python и R, полностью совпадают для всех трёх методов (Пирсон, Спирмен, Кендалл). Это подтверждает точность вычислений на обеих платформах.
- **Сравнение методов:**
 - Коэффициенты Пирсона дают максимальные значения для сильной линейной связи (температура и точка росы: 0.933)

- Коэффициенты Спирмена показывают сходные, но несколько меньшие значения (0.925)
- Коэффициенты Кендалла существенно ниже (0.768), что характерно для этого метода, так как он измеряет вероятность согласованности, а не силу связи

- **Физическая интерпретация:**

- Сильная связь температура-точка росы соответствует физическим законам термодинамики
- Отрицательная корреляция влажность-видимость объясняется метеорологическими явлениями
- Слабая связь скорости ветра с другими параметрами характерна для локальных погодных условий

- **Рекомендации по использованию:**

- Для линейных зависимостей предпочтительнее коэффициент Пирсона
- Для монотонных нелинейных зависимостей лучше подходят коэффициенты Спирмена и Кендалла
- Коэффициент Кендалла более устойчив к выбросам, но имеет меньшую мощность

16.4 Общие выводы

- Анализ выявил физически обоснованные взаимосвязи между метеорологическими параметрами
- Наиболее сильная связь наблюдается между температурой и точкой росы
- Влажность оказывает значительное влияние на видимость
- Давление слабо связано с температурными параметрами, но имеет умеренную связь со скоростью ветра
- Результаты Python и R полностью идентичны, что подтверждает надёжность корреляционного анализа на обеих платформах

- Выбор метода корреляции зависит от характера данных и целей анализа

16.5 Практическое значение

- Результаты могут быть использованы для улучшения прогнозных метеорологических моделей
- Выявленные связи помогают понимать комплексные атмосферные процессы
- Анализ демонстрирует важность многомерного подхода к изучению погодных явлений
- Методология может быть применена к другим наборам геофизических данных

17 Проверка зависимости между температурой и типом погоды с использованием различных тестов

17.1 Описание исследования

Целью исследования была проверка гипотезы о наличии зависимости между типом погоды (Weather) и температурой воздуха (Temp_C). Для анализа использовались три статистических теста: критерий хи-квадрат, точный тест Фишера и тест МакНемара, реализованные на Python и R.

17.1.1 Категоризация данных

- Температура (Temp_C) была разделена на четыре категории:
 - **-2**: Температура ниже -10°C
 - **-1**: Температура от -10°C до 0°C
 - **1**: Температура от 0°C до 10°C
 - **2**: Температура выше 10°C

- **Типы погоды** были сгруппированы следующим образом:
 - Основные категории: Clear, Cloudy, Drizzle, Fog, Mainly Clear, Mostly Cloudy, Rain, Rain Showers, Snow
 - **Others**: Редкие типы погоды (встречаются менее 100 раз)

17.1.2 Подготовка данных

Для анализа была построена таблица сопряжённости:

Temp_C	Clear	Cloudy	Drizzle	Fog	Mainly Clear	Mostly Cloudy	Others	F
-1	289	326	1	67	296	302	135	
-2	147	89	0	15	120	91	14	
1	302	537	87	208	338	558	42	
2	588	776	51	132	1352	1118	30	

Таблица 6: Таблица сопряжённости для категорий температуры и типа погоды.

17.2 Результаты теста хи-квадрат

17.2.1 Вывод Python

- p -значение: 0.0

17.2.2 Вывод R

- p -значение: 0

17.3 Результаты точного теста Фишера

17.3.1 Вывод Python

- Таблица сопряжённости для подвыборки:

	Cloudy	Clear
-1	326	289
-2	89	147

- p -значение: $6.674047129155591 \times 10^{-5}$

17.3.2 Вывод R

- Таблица сопряжённости для подвыборки:

	Cloudy	Clear
-1	326	289
-2	89	147

- p -значение: $6.67404712915556 \times 10^{-5}$

17.4 Результаты теста МакНемара

17.4.1 Вывод Python

- Таблица сопряжённости для теста МакНемара:

	Cloudy	Clear
1	537	302
2	776	588

- p -значение: $3.2311742677852644 \times 10^{-27}$
- Вывод программы: "Таким образом, данные зависимы в данных категориях"

17.4.2 Вывод R

- Таблица сопряжённости для теста МакНемара:

	Cloudy	Clear
1	537	302
2	776	588

- p -значение: $1.37546317972736 \times 10^{-24}$
- Вывод программы: "Таким образом, данные зависимы в данных категориях"

17.5 Выводы

- Все три статистических теста показывают статистически значимую зависимость между температурой воздуха и типом погоды ($p < 0.05$).
- Нулевая гипотеза (H_0) об отсутствии зависимости отвергается.
- **Интерпретация:** Существует сильная зависимость между температурой воздуха и типом погоды.

17.6 Обсуждение различий между Python и R

- Результаты теста хи-квадрат и точного теста Фишера полностью совпадают в Python и R.
- Для теста МакНемара наблюдаются различия:
 - Python: p -значение = 3.23×10^{-27}
 - R: p -значение = 1.38×10^{-24}
- Различия связаны с разными алгоритмами реализации теста МакНемара в библиотеках Python и R.
- Несмотря на различия, оба результата показывают $p < 0.05$, что позволяет сделать одинаковый статистический вывод о наличии зависимости между переменными.

18 Проверка наличия мультиколлинеарности в данных

19 Проверка мультиколлинеарности метеорологических переменных

19.1 Описание исследования

Целью исследования была проверка наличия мультиколлинеарности между метеорологическими переменными: температурой (Temp_C), точкой

росы (Dew Point Temp_C), относительной влажностью (Rel_Hum), скоростью ветра (Wind Speed_km/h), видимостью (Visibility_km) и атмосферным давлением (Press_kPa).

19.1.1 Категоризация данных

Все переменные являются непрерывными числовыми показателями метеорологических условий.

19.1.2 Подготовка данных

Для анализа были рассчитаны корреляционная матрица и фактор инфляции дисперсии (VIF).

19.2 Корреляционная матрица

19.2.1 Вывод Python

Корреляционная матрица:

	Temp_C	Dew Point Temp_C	Rel_Hum	Wind Speed_km/h	Visibility_km
Temp_C	1.000000	0.932714	-0.220182	-0.061876	0.273455
Dew Point Temp_C	0.932714	1.000000	0.139494	-0.095685	0.050813
Rel_Hum	-0.220182	0.139494	1.000000	-0.092743	-0.633683
Wind Speed_km/h	-0.061876	-0.095685	-0.092743	1.000000	0.004883
Visibility_km	0.273455	0.050813	-0.633683	0.004883	1.000000
Press_kPa	-0.236389	-0.320616	-0.231424	-0.356613	0.200000

Таблица 7: Корреляционная матрица, построенная на Python.

19.2.2 Вывод R

Корреляционная матрица:

	Temp_C	Dew.Point.Temp_C	Rel.Hum_	Wind.Speed_km.h	Visibi
Temp_C	1.000000	0.932714	-0.220182	-0.061876	0.273455
Dew.Point.Temp_C	0.932714	1.000000	0.139494	-0.095685	0.050813
Rel.Hum_	-0.220182	0.139494	1.000000	-0.092743	-0.633683
Wind.Speed_km.h	-0.061876	-0.095685	-0.092743	1.000000	0.004883
Visibility_km	0.273455	0.050813	-0.633683	0.004883	1.000000
Press_kPa	-0.236389	-0.320615	-0.231424	-0.356613	0.236389

Таблица 8: Корреляционная матрица, построенная на R.

19.3 Фактор инфляции дисперсии (VIF)

19.3.1 Вывод Python

- Для столбца Temp_C VIF равен 301.346
- Для столбца Dew Point Temp_C VIF равен 199.545
- Для столбца Rel_Hum VIF равен 445.414
- Для столбца Wind Speed_km/h VIF равен 3.995
- Для столбца Visibility_km VIF равен 10.251
- Для столбца Press_kPa VIF равен 794.380

19.3.2 Вывод R

- Для столбца Temp_C VIF равен 205.4081
- Для столбца Dew.Point.Temp_C VIF равен 198.9669
- Для столбца Rel.Hum_ VIF равен 28.5864
- Для столбца Wind.Speed_km.h VIF равен 1.2589
- Для столбца Visibility_km VIF равен 1.7893
- Для столбца Press_kPa VIF равен 1.4848

19.4 Выводы

- Сильная мультиколлинеарность обнаружена в переменных Temp_C, Dew Point Temp_C и Rel_Hum, где значения VIF значительно превышают 10.
- Переменные Wind Speed_km/h, Visibility_km и Press_kPa имеют низкие значения VIF, что подтверждает их относительную независимость.
- Корреляционные матрицы, полученные на Python и R, практически идентичны.
- Результаты VIF, полученные на Python и R, показывают схожие тенденции, но с численными различиями.

19.5 Обсуждение различий между Python и R

- Корреляционные матрицы полностью совпадают в Python и R.
- Для VIF наблюдаются значительные различия:
 - Python показывает экстремально высокие значения VIF для Press_kPa (794.38), Rel_Hum (445.41) и Temp_C (301.35)
 - R показывает более умеренные, но всё ещё высокие значения для тех же переменных
- Различия могут быть связаны с разными алгоритмами расчёта VIF, обработкой выбросов или спецификацией моделей в двух средах.
- Несмотря на различия в абсолютных значениях, оба подхода указывают на наличие сильной мультиколлинеарности между метеорологическими переменными.

20 Анализ влияния погодных условий на температуру и давление с использованием ANOVA

20.1 Описание исследования

Целью исследования была проверка влияния типа погоды на температуру воздуха и атмосферное давление с использованием однофакторного и двухфакторного дисперсионного анализа (ANOVA). Исследование проводилось на данных метеорологических наблюдений.

20.1.1 Параметры генерации данных для анализа

- **Типы погоды для анализа:**
 - Clear (ясно)
 - Mainly Clear (в основном ясно)
 - Mostly Cloudy (в основном облачно)
 - Cloudy (облачно)
 - Drizzle (морось)
 - Fog (туман)
- **Температурные категории:**
 - Категория -2: Температура ниже -10°C
 - Категория -1: Температура от -10°C до 0°C
 - Категория 1: Температура от 0°C до 10°C
 - Категория 2: Температура выше 10°C
- **Пример сгенерированных данных для проверки:**
 - 3 группы по 1000 наблюдений каждая
 - Нормальное распределение: $\text{loc} = 1$, $\text{scale} = 5$
 - Используется для проверки работы ANOVA при отсутствии различий между группами

20.1.2 Исследуемые переменные

- **Зависимые переменные:**

- Температура воздуха (Temp_C)
- Атмосферное давление (Press_kPa)

- **Независимые переменные:**

- Тип погоды (Weather): Clear, Mainly Clear, Mostly Cloudy, Cloudy, Drizzle, Fog
- Температура (как дискретная категориальная переменная)

20.2 Результаты однофакторного ANOVA

20.2.1 Вывод Python

- Сравниваемые группы: Clear, Mainly Clear, Mostly Cloudy
- p -значение: $4.814344194648583 \times 10^{-41}$
- Пример с сгенерированными данными: p -значение = 0.4772735611824669

20.2.2 Вывод R

- p -значение однофакторного ANOVA: $4.81434419463328 \times 10^{-41}$

20.3 Результаты двухфакторного ANOVA (температура непрерывная)

20.3.1 Вывод Python

Источник	Сумма квадратов	Степени свободы	F-статистика	p-знач
C(Weather)	462.082978	4.0	214.639483	9.236459
Temp_C	367.723772	1.0	683.236943	2.631955
C(Weather):Temp_C	27.976994	4.0	12.995431	1.552770
Residual	3053.793714	5674.0	-	-

Таблица 9: Результаты двухфакторного ANOVA (температура непрерывная) в Python

20.3.2 Вывод R

Источник	Сумма квадратов	Степени свободы	F-статистика	p-значение
Weather	480.85	4	223.356	$< 2.2 \times 10^{-16}$
Temp_C	367.72	1	683.237	$< 2.2 \times 10^{-16}$
Weather:Temp_C	27.98	4	12.995	1.553×10^{-1}
Residuals	3053.79	5674	-	-

Таблица 10: Результаты двухфакторного ANOVA (температура непрерывная) в R

20.4 Результаты двухфакторного ANOVA (температура дискретная)

20.4.1 Вывод Python

Источник	Сумма квадратов	Степени свободы	F-статистика	p-значение
C(Weather)	393.428336	4.0	185.919606	5.901604
Temp_C	430.340983	1.0	813.452601	2.540091
C(Weather):Temp_C	17.436210	4.0	8.239705	1.270414
Residual	3001.717287	5674.0	-	-

Таблица 11: Результаты двухфакторного ANOVA (температура дискретная) в Python

20.4.2 Вывод R

Источник	Сумма квадратов	Степени свободы	F-статистика	p-значение
Weather	480.85	4	227.2305	$< 2.2 \times 10^{-16}$
Temp_C	430.34	1	813.4526	$< 2.2 \times 10^{-16}$
Weather:Temp_C	17.44	4	8.2397	1.27×10^{-6}
Residuals	3001.72	5674	-	-

Таблица 12: Результаты двухфакторного ANOVA (температура дискретная) в R

20.5 Выводы

- Все p -значения в однофакторном и двухфакторном ANOVA являются статистически значимыми ($p < 0.05$).
- **Однофакторный ANOVA:** Температура воздуха статистически значимо различается между типами погоды Clear, Mainly Clear и Mostly Cloudy.
- **Двухфакторный ANOVA:** Как тип погоды, так и температура (как непрерывная, так и дискретная переменная) оказывают статистически значимое влияние на атмосферное давление.
- Наличие значимого взаимодействия Weather:Temp_C указывает на то, что влияние температуры на давление зависит от типа погоды.
- Проверочный пример со сгенерированными данными показал ожидаемый результат ($p = 0.477$), что подтверждает корректность работы метода ANOVA.

20.6 Обсуждение различий между Python и R

- Результаты однофакторного ANOVA полностью совпадают в Python и R.
- Для двухфакторного ANOVA наблюдаются небольшие различия в значениях сумм квадратов и F -статистик, что может быть связано с разными алгоритмами расчёта или округлением.
- В R p -значения представлены как $< 2.2 \times 10^{-16}$, что является минимальным значением, которое может быть представлено в данной системе.
- Несмотря на небольшие численные различия, статистические выводы одинаковы в обеих средах: все эффекты являются статистически значимыми.

21 Аппроксимация данных с использованием регрессионных моделей

21.1 Описание исследования

Для анализа зависимости между давлением ($y = Press_kPa$) и независимыми переменными ($Temp_C$, Rel_Hum , $Wind\ Speed_km/h$, $Dew\ Point\ Temp_C$, $Visibility_km$) были построены регрессионные модели с регуляризацией:

- LASSO регрессия (L1-регуляризация).
- Гребневая регрессия (Ridge, L2-регуляризация) с полиномиальными признаками.

Для оценки качества моделей использовались следующие метрики:

- MSE (среднеквадратическая ошибка).
- Стандартное отклонение целевой переменной.
- Коэффициент детерминации R^2 .

21.2 Результаты анализа

21.2.1 LASSO регрессия (Python)

LASSO регрессия с $\alpha = 1$ показала следующие результаты:

- Величина MSE: 0.2458
- Стандартное отклонение целевой переменной: 0.8440
- Коэффициенты модели:
 - $Temp_C$: -0.0000 (занулен)
 - Rel_Hum : -0.0049
 - $Wind\ Speed_km/h$: -0.0247
 - $Dew\ Point\ Temp_C$: -0.0177
 - $Visibility_km$: 0.0064

LASSO занулила коэффициент при переменной $Temp_C$, которая сильно коррелирует с $Dew\ Point\ Temp_C$, что демонстрирует способность метода отбирать наиболее информативные признаки.

21.2.2 Полиномиальная регрессия с Ridge регуляризацией (Python)

С помощью GridSearchCV были подобраны оптимальные гиперпараметры:

- Степень полинома: 5
- Включение константы: True
- Масштабирование: без масштабирования ('passthrough')
- Лучший R^2 на кросс-валидации: 0.3326

Для полиномиальной модели степени 4 с Ridge регуляризацией ($\alpha = 1$):

- Величина MSE: 0.2261
- Стандартное отклонение целевой переменной: 0.8440

21.2.3 Сравнение с R

Модель	Python	R
Ridge (без полиномов)		
MSE	0.2457	0.5729
Ridge (с полиномами степени 4)		
MSE	0.2261	0.4926

Таблица 13: Сравнение MSE для Ridge регрессии в Python и R

В R были получены следующие результаты:

- Ridge регрессия без полиномов: $MSE = 0.5729$
- Ridge регрессия с полиномами степени 4: $MSE = 0.4926$

21.3 Выводы

- **Эффективность регуляризации:**

- LASSO регрессия успешно выполняет отбор признаков, зануляя коэффициент при коррелированной переменной *Temp_C*.
- Ridge регрессия с полиномиальными признаками показывает лучшие результаты по сравнению с линейной моделью.

- **Сравнение Python и R:**

- Python демонстрирует значительно лучшие результаты для полиномиальной регрессии ($MSE = 0.2261$ против 0.4926 в R).
- Различия могут быть обусловлены особенностями реализации полиномиальных преобразований и алгоритмов регуляризации в разных библиотеках.
- В Python наблюдалось предупреждение о плохо обусловленной матрице при построении полиномиальной модели, что может указывать на мультиколлинеарность признаков.

- **Качество моделей:**

- Наилучший результат достигнут с помощью полиномиальной Ridge регрессии в Python ($MSE = 0.2261$).
- Несмотря на улучшение по сравнению с базовыми моделями, величина ошибки остается значительной относительно стандартного отклонения целевой переменной.

22 Общее сравнение Python и R

22.1 Общие наблюдения

В ходе анализа регрессионных моделей с регуляризацией были выявлены следующие особенности:

- **Качество результатов:** Python показал лучшие результаты для полиномиальной регрессии, что может быть связано с более оптимальной реализацией алгоритмов работы с полиномиальными признаками.

- **Диагностика проблем:** Python предоставил предупреждение о плохо обусловленной матрице, что помогает идентифицировать потенциальные проблемы с данными.
- **Гибкость настройки:** В Python проще осуществлять подбор гиперпараметров через GridSearchCV и создание сложных пайплайнов.

22.2 Заключение

- Для задач регрессии с регуляризацией и полиномиальными преобразованиями Python демонстрирует преимущество в качестве результатов и удобстве настройки моделей.
- LASSO регрессия эффективно справляется с отбором признаков в условиях мультиколлинеарности.
- Различия в результатах между Python и R подчеркивают важность внимательного выбора инструментов и понимания особенностей их реализации для конкретных аналитических задач.

23 Выводы

В процессе выполнения задания по курсу «Технологический практикум» я освоил применение инструментов статистического анализа данных на языках программирования R и Python. Были изучены свойства различных датасетов, включая данные о качестве сна, уровне счастья в мире за 2021 и 2023 годы, а также информацию о различных видах хлопьев.

Для анализа данных мной были использованы ключевые статистические методы и техники:

- **Визуализация данных:** построены графики `cdplot`, `dotchart`, `boxplot` и `stripchart`, что позволило наглядно представить распределение и вариативность данных.
- **Выявление выбросов:** применены критерии Граббса и Q-тест альДиксона для обнаружения аномальных значений в выборках.

- **Исследование нормальности распределения:** проанализированы свойства нормально распределённых выборок с помощью графиков эмпирических функций распределения, квантилей и метода огибающих, а также проведены стандартные процедуры проверки гипотез о нормальности.
- **Аппроксимация распределений:** выполнена оценка плотности распределения данных с помощью ядерных оценок, что позволило более точно охарактеризовать поведение случайных величин.
- **Обработка пропусков:** изучены и применены инструменты заполнения пропусков в данных, обеспечивающие корректный анализ даже при неполноте исходной информации.

Кроме того, я научился формулировать и проверять статистические гипотезы, используя следующие техники:

- **Параметрические и непараметрические тесты:** критерии Стьюдента, Уилкоксона-Манна-Уитни, Фишера и другие.
- **Корреляционный анализ:** исследованы взаимосвязи между переменными с помощью коэффициентов корреляции Пирсона, Спирмена и Кендалла.
- **Критерии независимости:** применены методы хи-квадрат, Фишера, МакНемара и Кохрана-Мантеля-Хензеля для проверки независимости распределений.

Важным этапом работы стала проверка наличия мультиколлинеарности в данных с использованием корреляционной матрицы и фактора инфляции дисперсии (VIF). Также был проведён дисперсионный анализ (однофакторный и двухфакторный) и подгонка регрессионных моделей под имеющиеся данные, что позволило выявить основные влияющие факторы и построить предсказательные модели.

Все применённые методы были успешно реализованы на выбранных датасетах, что позволило глубоко проанализировать представленные данные и сделать обоснованные выводы. В результате выполнения данного задания я значительно повысил свои навыки в области статистического анализа данных и их интерпретации.

Кроме того, результаты, полученные с использованием языков программирования Python и R, оказались практически идентичными, что подтверждает возможность применения обоих языков программирования для статистического анализа данных.

Список литературы

1. Брюс П., Брюс Э., Гедек П. Практическая статистика для специалистов Data Science. – 2-е изд., перераб. и доп. — СПб.: БХВ-Петербург, 2021. – 352 с.
2. Мастицкий С.Э., Шитиков В.К. Статистический анализ и визуализация данных с помощью R. – М.: ДМК Пресс, 2015. – 496 с.
3. Нильсен Э. Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение. – СПб.: ООО «Диалектика», 2021. – 544 с.