

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В. ЛОМОНОСОВА

Факультет вычислительной математики и кибернетики

ОТЧЕТ ПО СОЗДАНИЮ RAG-системы НА ОСНОВЕ LLM

Выполнил:

студент 316 группы

Дзюба Иван

Москва, 2026

1 Введение

Во время выполнения домашнего задания были использованы следующие модели: **Qwen/Qwen3-4B** и **Qwen/Qwen2.5-3B-Instruct**, далее идет их краткое описание. Данные модели имеют обинаковую архитектуру, и их основное отличие - размер и мощность, таким образом, можно сравнить эффективность подобных, относительно небольших моделей в задачах поиска. Были выбраны модели малого размера, так как это должно уменьшить ресурсопотребление системы на операциях, не требующих большой памяти модели.

Qwen/Qwen2.5-0.5B-Instruct

Qwen/Qwen2.5-0.5B-Instruct — это модель на 0.5B параметров (494 млн), которая в формате FP16 занимает около 1 ГБ памяти, а в int8 — около 0.5 ГБ. Она поддерживает контекст в 32K токенов и считается лучшей в своем классе до 1B параметров, обгоняя конкурентов вроде TinyLlama и Phi-1.5 по мультязычности и работе с длинными текстами.

Qwen/Qwen2.5-3B-Instruct

Qwen/Qwen2.5-3B-Instruct — это модель на **3B параметров** (3.09 млрд), которая в формате FP16 занимает около **6 ГБ памяти**, а в int8 — около **3 ГБ**. Она поддерживает контекст в **32K токенов** и считается **оптимальным балансом между производительностью и потреблением ресурсов** в линейке Qwen2.5, обеспечивая качество, близкое к моделям на 7B, при значительно меньших требованиях к памяти и инференсу.

1.1 Описание задачи

Задача состоит в том, чтобы извлечь вопросов, контекста, связанного с вопросом, и приемлемого ответа для создания RAG-подобной системы, провести тестирование на основе данных из датаета.

Шаги выполнения:

1) Был загружен датасет, из него были извлечены уникальные элементы поля контекст в виде списка 2) Была построена векторная база данных на основе QDrant, хранящая векторизованные представления текстов контекстов. 3) Была реализована функция, получающая на вход вопрос, ищущая контекст, связанный с вопросом в базе данных с помощью косинусного расстояния, затем передающая БЯМ вопрос и связанный контекст и возвращающая ответ модели.

Результаты:

Были получены следующие результаты: 0.5 гб: 2 2 0 2 2 1 1 1 1 0 3 гб: 2 2 2 2 2 1 1 1 2 2
Здесь, 0-модель ответила нелогично, 1-неверно, но логично, 2- ответ верный. Моделям были поданы 40 наиболее близких контекстов, данное число было подобрано эмпирически, при большем числе контекстов модель не могла найти нужную информацию, при меньшем в группу с наиболее подходящим контекстом часто не попадал в выборку. По результатам эксперимента можно сделать следующие выводы: Большая модель имеет большую способность к пониманию вопроса, чем меньшая, так же, стоит отметить недоработки в создании векторной бд: при создании добавлялось много контекста, не содержащего какую-либо информацию, следовательно, при создании RAG нужно уделять большое внимание борьбе с мусором в БД, работа над данной проблемой позволит уменьшить объем необходимой информации, подаваемой в БЯМ, что повысит скорость работы системы и ее точность. так как сосредоточит внимание БЯМ на полезной информации. Потенциально хороший путь в сортировке мусора в БД-применение специально обученной БЯМ.

Выводы:

Таким образом, можно сказать, что использование малых БЯМ для решения данных задач допустимо, но для этого необходимо хорошо фильтровать базу данных с информацией. Так же, стоит отметить, что меньшая модель выглядит более оптимальной на фоне большей, так как при размере в 6 раз меньше, она дает точность чуть больше, чем в 2 раза больше, причем, точность можно повысить, улучшив методы поиска и фильтрации в базе данных.